

Bayesiansk statistik, 732g43, 7.5 hp

Moment 4 - Logistisk regression, Binomialregression, Poissonregression,
Multilevelmodeller

Bertil Wegmann

STIMA, IDA, Linköpings universitet

- Bayesiansk logistisk regression
- Bayesiansk binomialregression
- Bayesiansk Poissonregression
- Bayesianska multilevelmodeller

- Den beroende variabeln Y är binär, d.v.s. antingen är $Y = 0$ eller $Y = 1$. Vi vill anpassa en modell där $P(Y = 1)$ beror på olika förklaringsvariabler i en regressionsmodell.
- Modellen kan skrivas som

$$y_i \stackrel{iid}{\sim} \text{bin}(1, p_i)$$

$$\log \left(\frac{p_i}{1 - p_i} \right) = \text{logit}(p_i) = \mathbf{x}_i \boldsymbol{\beta},$$

där $\boldsymbol{\beta} = (\beta_0 \beta_1 \dots \beta_k)$ är en kolumnvektor med parametrar och $\mathbf{x} = (1 x_1 \dots x_k)$ en radvektor med förklaringsvariabler.

- Oberoende priors för $\boldsymbol{\beta}$ (boken):

$$\beta_j \sim N(0, 10),$$

där $j = 0, 1, \dots, k$.

- Wegmann och Villani (2011) analyserade förpackningar av samlarmynt från 1000 auktioner på auktionssajten eBay. Datamaterialet “eBaydata” finner ni på kurshemsidan och består av
 - beroende variabel $y = UnOpen$: en dummyvariabel med värdet 1 om myntförpackningen levereras sluten och öppen i dess originalförpackning.
 - förklaringsvariabel $x_1 = PowerSeller$: en dummyvariabel med värdet 1 om säljaren är rankad bland de mest lyckosamma försäljarna på eBay.
 - förklaringsvariabel $x_2 = LogBookValue$: naturliga logaritmen av priset på myntförpackningen från den stora myn্থandlaren Golden Eagle Coins på Internet (<http://www.goldeneaglecoin.com>).

- Jämför resultaten mellan följande 4 modeller: **#R kod 4.1**
 - 1 Modell_utan: Bayesiansk logistisk regressionsanalys utan förklaringsvariabler.
 - 2 Modell_x1: Bayesiansk logistisk regressionsanalys med endast förklaringsvariabeln x_1 .
 - 3 Modell_x2: Bayesiansk logistisk regressionsanalys med endast förklaringsvariabeln x_2 .
 - 4 Modell_x1x2: Bayesiansk logistisk regressionsanalys med båda förklaringsvariabler.

- Log-oddset förändras med $m\beta_j$ då en förklaringsvariabel x_j ökar med m enheter, givet att $(x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_k)$ hålls konstanta.
- Oddset förändras med en faktor $e^{m\beta_j}$ då en förklaringsvariabel x_j ökar med m enheter, givet att $(x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_k)$ hålls konstanta.

- Den beroende variabeln Y är binomialfördelad. Vi vill anpassa en modell där sannolikheten för lyckat försök för observation i , p_i , beror på olika förklaringsvariabler i en regressionsmodell.
- Modellen kan skrivas som

$$y_i \stackrel{iid}{\sim} \text{bin}(n_i, p_i)$$

$$\log \left(\frac{p_i}{1 - p_i} \right) = \text{logit}(p_i) = \mathbf{x}_i \boldsymbol{\beta},$$

där $\boldsymbol{\beta} = (\beta_0 \beta_1 \dots \beta_k)$ är en kolumnvektor med parametrar och $\mathbf{x} = (1 x_1 \dots x_k)$ en radvektor med förklaringsvariabler.

- Oberoende priors för $\boldsymbol{\beta}$ (boken):

$$\beta_j \sim N(0, 10),$$

där $j = 0, 1, \dots, k$.

- Graduate school ansökningar för män och kvinnor till 6 olika institutioner på UC Berkley (ett av bokens datamaterial). Data kolumner innehåller för respektive kön och institution antal ansökningar (*applications*) samt antal beviljade (*admit*) och icke-beviljade (*reject*) ansökningar. **#R kod 4.2**
- Totalt antal ansökningar är 4526, varav 1755 stycken eller 38.8 % beviljades.
- Mål med binomialregression: avgöra om kön kan förklara sannolikheten att en ansökan beviljas eller ej.

- 2 modeller med y = antal beviljade per kön och institution och med eller utan dummyvariabeln $x_1 = 1$ om ansökan kom från en man och 0 annars:

$$y_i \stackrel{iid}{\sim} \text{bin}(n_i, p_i)$$

$$\log \left(\frac{p_i}{1 - p_i} \right) = \text{logit}(p_i) = \beta_0 + \beta_1 x_{1i},$$

där n_i är antalet ansökningar (applications) och p_i är sannolikheten för att en ansökan beviljas för en kombination i av kön och institution.

- Resultatet visar på att sannolikheten för en beviljad ansökan är i genomsnitt över institutioner betydligt högre för män än kvinnor.
- Vad kan detta resultat bero på?

- Posterior prediktiv check visar att modellen är dålig på att skatta andelen beviljade ansökningar för män och kvinnor per institution.
- Kvinnor har en högre andel beviljade ansökningar på flera institutioner.
- Skillnaderna mellan män och kvinnors andel beviljade ansökningar bottnar i att kvinnor har i högre grad ansökt till institutioner som beviljar en betydligt lägre andel ansökningar.
- Omformulering av mål med binomialregression: avgöra hur stor skillnaden är i sannolikhet för beviljad ansökan mellan könen per institution?

■ Modell:

$$y_i \stackrel{iid}{\sim} \text{bin}(n_i, p_i)$$

$$\log \left(\frac{p_i}{1 - p_i} \right) = \text{logit}(p_i) = \beta_{0j} + \beta_1 x_{1i},$$

$$\beta_{0j} \stackrel{iid}{\sim} N(0, 10),$$

$$\beta_1 \sim N(0, 10),$$

där index $j = 1, \dots, 6$, är för varje institution j .

- Akaikevikter för de 4 modellerna med WAIC: med/utan dummyvariabel för män och med/utan olika intercept för institutioner.
- Akaikevikterna visar på att det är ungefär fifty-fifty att modellerna med olika intercept för institutioner med/utan dummyvariabel för män är bäst på att göra prediktioner.
- Oddset för beviljad ansökan förväntas förändras med en faktor $e^{-0.1} = 0.9$, där -0.1 är posterior medelvärde för parametern till dummyvariabeln x_1 , från en kvinna till en man som ansöker.
- Fördelningen för faktorn som oddset förändras med visar att det är mer troligt att en ansökan från en kvinna blir beviljad per institution, men skillnaden är liten.
- Posterior prediktiv check visar att modellen är nu mycket bättre på att skatta andelen beviljade ansökningar för män och kvinnor per institution.

- Modell:

$$y_i \stackrel{iid}{\sim} \text{Poisson}(\lambda_i)$$

$$\log \lambda_i = \mathbf{x}_i \boldsymbol{\beta},$$

där $\boldsymbol{\beta} = (\beta_0 \beta_1 \dots \beta_k)$ är en kolumnvektor med parametrar och $\mathbf{x} = (1 \ x_1 \dots x_k)$ en radvektor med förklaringsvariabler.

- Oberoende priors för $\boldsymbol{\beta}$:

$$\beta_j \sim N(0, 10),$$

där $j = 0, 1, \dots, k$.

- Antalet awards för studenter på ett high school, y , kan bero på antalet skrivningspoäng på ett matematiktest ($x_1 = \text{math}$ i hundratal) och vilket av följande tre studieprogram som studenten går på: akademiskt (academic), allmänt (general) eller yrkesprogram (vocation).
- I exemplet på

<https://stats.idre.ucla.edu/r/dae/poisson-regression/>

har data samlats in för variablerna ovan. **#R kod 4.3**

- En Bayesiansk Poisson regression ska anpassas till datamaterialet.

- Studieprogrammen kodas om till
 $1 = \textit{academic}$, $2 = \textit{general}$, $3 = \textit{vocational}$.
- Poisson regression med olika intercept för program:

$$y_i \stackrel{iid}{\sim} \textit{Poisson}(\lambda_i)$$

$$\log(\lambda_i) = \beta_{0j} + \beta_1 x_{1i},$$

$$\beta_{0j} \stackrel{iid}{\sim} N(0, 10),$$

$$\beta_1 \sim N(0, 10),$$

där index $j = 1, 2, 3$ för varje program j .

- Akaikevikter för 4 modeller med WAIC: med/utan förklaringsvariabel $x_1 = \textit{math}$ och med/utan olika intercept för program.
- Akaikevikterna visar på att förklaringsvariabeln *math* ska vara med i modellen tillsammans med/utan intercept för program.
- Sannolikheten är ungefär 99 % att modellen med *math* tillsammans med intercept för program är bäst på att göra prediktioner jämfört med sannolikheten på 1 % för modellen med endast *math*.
- 90.9 % kredibilitetsintervall för λ och y kan skapas som funktion av *math*.
- Posterior prediktiv check med kredibilitetsintervallen ovan visar att modellen skattar antalet awards på ett ok sätt, men modellen verkar ha problem med ökande varians i antalet awards då *math* ökar.

- Wänström och Wegmann (2017) analyserade hur antalet yngre och äldre syskon påverkar barns intelligensnivå.
- Datamaterialet *Individual Development and Adaptation (IDA)* inkluderar alla skolbarn ($n=665$) i årskurs 3 på lågstadiet i normala skolor i Örebro, 1965. Barnen följdes även upp i vuxen ålder omkring år 2000 för att bland annat studera karriärval och inkomstnivå.
- Effekt på intelligensnivå kan också förklaras med hjälp av andra variabler. Från datamaterialet extraherades följande bakgrundsvariabler:
 - socioekonomisk status (SES)
 - föräldrars ålder (M.age och F.age)
 - kön (Gender)

- Datamaterialet innehåller också information om vilken klass respektive elev (barn) tillhörde. Det är naturligt att ta hänsyn till olika klassmiljöer som kan innebära olika skillnader i intelligensnivå mellan elever i olika klasser.
- Skolklasserna är ett urval från populationen med alla skolklasser i årskurs 3 på lågstadiet i Sverige. Därför vill man kunna generalisera effekterna till populationen barn i alla skolklasser. Därmed valdes en Bayesiansk multilevelmodell (random effects model) med skolklasser som gruppvariabel (klustervariabel).
- Enbart generalisera resultaten till barnen i studien - fixed effects model med dummyvariabler för klasstillhörighet kan väljas. Detta kan dock ge osäkra skattningar i små klasser med få antalet barn.
- Multilevelmodellen som kan användas kallas för Bayesiansk varierande-intercept modell, eftersom den modellerar olika intercept för olika skolklasser.

■ Multilevelmodell med 2 nivåer:

$$y_i \stackrel{iid}{\sim} N(\mu_i, \sigma_y)$$

$$\mu_i = \alpha_j + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i},$$

$$\alpha_j \sim N(\alpha, \sigma_\alpha),$$

$$\alpha \sim N(0, 10),$$

$$\sigma_\alpha \sim \text{halfcauchy}(0, 1),$$

$$\beta_k \sim N(0, 10),$$

$$\sigma_y \sim \text{halfcauchy}(0, 1),$$

där $y = IQ$, x_1 är antalet äldre syskon (Older), x_2 är antalet yngre syskon (Young), $x_3 = 1$ för pojke och 0 för flicka, $x_4 = SES$, x_5 och x_6 är åldersklass för respektive moderns och faderns ålder vid födseln (M.age och P.age). Index $j = 1, \dots, 46$ är för skolklass j och index $k = 1, \dots, 6$ är för förklaringsvariabel k .

- Kvadratisk approximation fungerar inte, eftersom modellen består av 2 nivåer och därmed inte ger en enhetlig funktion för log av posteriorn → MCMC till vår tjänst med hjälp av funktionen *map2stan()*.
- Priorn för intercepten α_j kallas för *hyperprior*, eftersom *hyperpriorn* beror på priorn för dess *hyperparametrar* α och σ_α .
- Posterior resultaten visar att det är väldigt troligt att barn med fler antalet äldre syskon har, i genomsnitt, lägre IQ än barn med färre antalet äldre syskon.
- Posterior resultaten visar att det är väldigt troligt att barn med högre SES har, i genomsnitt, högre IQ än barn med lägre SES.
- MCMC diagnostik visar på konvergens till posteriorn utifrån $n_{eff} > 100$, $\hat{R} < 1.1$, zick-zack mönster i MCMC trace plott och stabilisering av posterior medelvärdet för varje parameter över MCMC iterationerna.

- Om observationerna tillhör olika grupper, så bör man givetvis ta hänsyn till den gruppsspecifika strukturen. Särskilt viktigt om det finns mycket heterogenitet mellan homogena grupper.
- Modellen lär sig om varje enskild grupp (kluster) samtidigt som den lär sig om populationen av grupper (kluster). Modellen poolar information över grupperna.
- En grupp med lite data påverkas mer av den poolade informationen. Naturligt, eftersom lite data för en grupp innebär lite information om den specifika gruppen.
- Prior för varje intercept krymper alla intercept mot deras gemensamma medelvärde α (*shrinkage effect*). Prior är en regulariserande prior för intercepten som uppdateras från data.

- Modellen tar hänsyn till all variation inom och mellan grupper jämfört med en modell utan varierande intercept som väger alla observationer lika mycket till ett enda intercept.
- Modellen skattar variationen inom grupper med σ_y^2 och variationen mellan grupper med σ_α^2 . Intraklasskorrelationen mäter andel variation mellan grupperna som

$$\rho_{ICC} = \frac{\sigma_\alpha^2}{\sigma_y^2 + \sigma_\alpha^2}.$$

- Posteriorfördelningar för variation inom och mellan grupper ger posteriorfördelningen för intraklasskorrelationen.
- Intraklasskorrelationen är ett mått på hur starkt sambandet är mellan observationer inom samma grupp.
- Wänström och Wegmann (2017) visar en genomsnittlig intraklasskorrelation på 0.44 i en modell utan förklaringsvariabler, vilket innebär en ganska hög andel variation i *IQ* mellan grupperna.

- Multilevelmodell med 2 nivåer: **#R kod 4.5**

$$y_i \stackrel{iid}{\sim} \text{bin}(1, p_i)$$

$$\log \left(\frac{p_i}{1 - p_i} \right) = \text{logit}(p_i) = \alpha_j + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i},$$

$$\alpha_j \sim N(\alpha, \sigma_\alpha),$$

$$\alpha \sim N(0, 10),$$

$$\sigma_\alpha \sim \text{halfcauchy}(0, 1),$$

$$\beta_k \sim N(0, 10),$$

där $y = 1$ om det är minst 4 barn i familjen, $x_1 = \text{SES}$, x_2 och x_3 är åldersklass för respektive moderns och faderns ålder vid födseln (M.age och P.age). Index $j = 1, \dots, 46$ är för skolklass j och index $k = 1, 2, 3$ är för förklaringsvariabel k .

- Multilevelmodell med 2 nivåer:

$$y_i \stackrel{iid}{\sim} \text{bin}(1, p_i)$$

$$\log \left(\frac{p_i}{1 - p_i} \right) = \text{logit}(p_i) = \alpha_j + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i},$$

$$\alpha_j \sim N(\alpha_0 + \alpha_1 x_{5j}, \sigma_\alpha),$$

$$\alpha_0 \sim N(0, 10),$$

$$\alpha_1 \sim N(0, 10),$$

$$\sigma_\alpha \sim \text{halfcauchy}(0, 1),$$

$$\beta_k \sim N(0, 10),$$

där $y = 1$ om det är minst 4 barn i familjen, $x_1 = \text{SES}$, x_2 och x_3 är åldersklass för respektive moderns och faderns ålder vid födseln (M.age och P.age) och x_5 är en förklaringsvariabel på gruppnivå. Index $j = 1, \dots, 46$ är för skolklass j och index $k = 1, \dots, 3$ är för förklaringsvariabel k .

- Man kan dela upp information från pooling mellan grupper i 3 kategorier:
 - fullständig pooling: modellen innehåller endast ett intercept för alla grupper.
 - ingen pooling: $J - 1$ dummyvariabler för J grupper. Information från data för en grupp är irrelevant information till alla andra grupper.
 - delvis pooling: adaptiv regulariserande prior för gruppernas intercept i en multilevelmodell.

- Fullständig pooling underanpassar data genom att ge precis information om endast ett intercept för alla observationer och som kan skilja sig mycket från intercepten i grupperna då intraklasskorrelationen är stor.
- Ingen pooling ger icke-precis information om interceptet i varje grupp, eftersom det är endast data i respektive grupp som uppskattar sitt intercept. Detta medför särskilt stor osäkerhet i skattning av interceptet i grupper med lite data, vilket innebär att modellen överanpassar data med lite information i dessa grupper.
- Delvis pooling i multilevelmodeller med regulariserande prior ger skattningar av gruppsspecifika intercept som underanpassar mindre i förhållande till fullständig pooling och överanpassar data mindre för grupper med lite data, eftersom intercepten för dessa grupper lånar styrka från andra grupper och krymper mer mot genomsnittliga interceptet för alla grupper.

- Informationskriterier som DIC och WAIC kan användas som förut för att jämföra modellers prediktionsförmåga på nya data (out-of-sample deviance).
- Den adaptiva regulariserande priorn för intercepten i multilevelmodeller minskar överanpassning av data för att ge bättre prediktionsförmåga - multilevelmodeller kan därför aldrig replikera data exakt, eftersom regulariseringen ger en sämre modellanpassning till data.
- Skilj på om modellens prediktiva förmåga ska utvärderas för de specifika grupperna i data (fixed effects) eller om utvärderingen ska kunna generaliseras till populationen med alla grupper (random effects).
- Oavsett modell med fixed eller random effects: Bayesianska modeller är generativa, så simulering från modellen med samplade posteriorvärden för parametrarna ger prediktioner i form av simulerad data. Posteriorfördelningen för prediktioner kan sedan sammanfattas.

- Posterior prediktioner för specifika grupper i data som användes till skattning av modellen: specificera vilken grupp och därmed vilket intercept man ska använda för att generera prediktioner i modellen.
- Posterior prediktioner för nya grupper som inte fanns i den data som användes till skattning av modellen: fördelningen för de varierande intercepten är intressant.
- Posterior prediktioner för en ny grupp som antas vara en genomsnittlig grupp: genomsnittliga interceptet α används för att generera prediktioner i modellen.
- Posterior prediktioner för en ny specifik grupp $J + 1$ som inte antas vara genomsnittlig: för varje posteriordragning s av α och σ_α dras α_{J+1} från $\alpha_{J+1,s} \sim N(\alpha_s, \sigma_{\alpha,s})$ och för varje intercept $\alpha_{J+1,s}$ genereras en prediktion i modellen. Prediktionerna genereras alltså från lika många genererade intercept $\alpha_{J+1,s}$ som antalet posteriordragningar i MCMC:n.